

Sprint Planning 3

Modelos, RNN e API



INTELI

Engenharia de Computação
Módulo 07 - Sistema de manutenção
preditiva com IA e arquitetura em nuvem

Setembro - 2026

Sprint Planning 3: modelos, RNN e análise financeira

Metas do encontro:

- Alinhar como o rótulo nasce do cruzamento entre alarmes e chamados
- Definir os critérios que tornam dois modelos comparáveis
- Tratar o desbalanceamento dos dados de forma explícita e justificada
- Apresentar os artefatos da sprint 3 e seus baremas
- Montar o backlog da sprint no Kanban

De onde vem o dado: alarmes e chamados

Quem define quando algo aconteceu é a tabela de chamados.

A verdade do problema está na tabela de chamados

O alarme é um sinal, não é o evento. Ele indica que um limite foi violado, mas não confirma que houve falha, parada ou necessidade de manutenção.

O chamado é o registro da ocorrência reconhecida pela operação. Ele traz data, ativo, tipo de ocorrência e desfecho. É esse registro que define quando algo aconteceu.

Consequência prática: o rótulo (y) vem da tabela de chamados. Os alarmes, e as variáveis derivadas deles, compõem as features (X).


Erro a evitar: treinar o modelo para prever alarme. O parceiro já tem a regra que dispara o alarme. O valor está em antecipar o chamado.

Como o exemplo de treino é construído

Cada exemplo é um par (ativo, instante de referência t_0).


Janela de observação

Alarmes anteriores a t_0 : contagens, severidade, frequência, tempo desde o último alarme



t_0 : instante da predição

Nada posterior a t_0 pode entrar em X. Este é o ponto de corte do vazamento



Horizonte de predição

$y = 1$ se existe chamado para o ativo dentro da janela (por exemplo, 7 dias)

- A janela de observação e o horizonte de predição são decisões do time e precisam estar na documentação
- O mesmo par de janelas vale para todos os modelos comparados na sprint
- A API precisa receber exatamente o que a janela de observação exige

Associação entre alarmes e chamados

Regras a definir e registrar

- Chave de ligação entre as tabelas: ativo, equipamento ou local
- Tolerância de tempo entre o alarme e a abertura do chamado
- Janela de observação e horizonte de predição, com a unidade de análise (ativo por dia, por exemplo)
- Critério para chamados sem alarme correspondente e para alarmes sem chamado
- Tratamento de chamados duplicados, reincidências e ordens preventivas

Armadilhas frequentes

- Usar o alarme como rótulo: o modelo apenas reaprende a regra que já existe
- Vazamento temporal: features calculadas com dados posteriores a t_0
- Split aleatório em dados temporais: o corte precisa ser por tempo, e por ativo quando fizer sentido
- Mudar a definição do rótulo entre um experimento e outro, o que invalida a comparação

Escolha e comparação de modelos

Comparar só faz sentido quando os modelos respondem à mesma pergunta.

0 que precisa ser igual para dois modelos serem comparáveis

- **Tarefa e alvo:** a variável y com a mesma definição, mesma janela e mesmo horizonte
- **Unidade de análise:** ativo por dia, ativo por semana ou ocorrência, mantida em todos os experimentos
- **Conjunto de dados e partição:** mesmo recorte de treino, validação e teste, com o mesmo corte temporal
- **Pré-processamento:** mesmo tratamento de faltantes, mesma normalização e mesma engenharia de atributos de base
- **Métrica principal:** uma métrica definida antes dos experimentos, com o limiar de decisão explicitado
- **Condição de treino:** critério de parada, seed e busca de hiperparâmetros documentados

Se qualquer um desses itens muda, a diferença observada não pode ser atribuída ao modelo.

Comparação inválida e comparação válida

Não comparável

- Modelo A: classifica se haverá chamado nos próximos 7 dias. Resultado em F1
- Modelo B: estima quantos dias faltam até o próximo chamado. Resultado em erro médio absoluto
- São tarefas diferentes, com métricas em escalas diferentes. Não existe conclusão sobre qual é melhor

Comparável

- Modelo A: baseline sobre features agregadas de alarmes, alvo de 7 dias
- Modelo B: RNN sobre a sequência de alarmes, mesmo alvo, mesmo split, mesma métrica
- A diferença observada mede o efeito da arquitetura, e não uma mudança de problema

Um modelo de regressão do tempo até a falha pode continuar no projeto. Ele entra como um segundo experimento, com a sua própria tabela de resultados, e não na mesma comparação.

Protocolo mínimo de comparação

- Definir o alvo e registrar essa definição na documentação do modelo
- Fixar a partição temporal e reutilizá-la em todos os experimentos
- Estabelecer dois baselines: um modelo simples e a regra atual do alarme
- Ajustar hiperparâmetros na validação, nunca no conjunto de teste
- Avaliar no teste uma única vez e reportar a métrica principal com as secundárias
- Registrar seed, versão dos dados, tempo de treino e tempo de inferência
- Consolidar tudo em uma tabela única: modelo, features, métrica principal, métricas secundárias e custo

O modelo anterior permanece na documentação. A evolução entre as sprints precisa ficar visível nessa tabela.

Dados desbalanceados

O evento de interesse é raro. A métrica precisa refletir isso.

Por que a acurácia engana neste problema

Situação típica: se 2% das observações têm chamado, um modelo que responde sempre “não haverá chamado” alcança 98% de acurácia e não entrega valor algum para a operação.

Antes de treinar: reportar a proporção de positivos no total, por ativo e por período. Esse número orienta a escolha da métrica, do limiar e da estratégia de treino.

Verificar também: se a proporção de positivos é parecida em treino, validação e teste. O corte temporal pode concentrar eventos em um período específico.

A proporção de positivos é um dado da documentação dos dados, e não um detalhe de implementação. Ela sustenta a justificativa das escolhas cobradas no barema.

Métricas e limiar de decisão

- **Matriz de confusão:** ponto de partida, sempre reportada junto das demais métricas
- **Precisão e revocação da classe positiva:** com F1 quando o equilíbrio entre as duas for aceitável para o negócio
- **PR-AUC:** a curva precisão-revocação é mais informativa que a ROC-AUC quando a classe positiva é rara
- **Revocação em k alertas:** útil quando a operação inspeciona um número limitado de ativos por semana
- **Limiar:** é uma decisão de negócio: falha não prevista e inspeção desnecessária têm custos diferentes
- **Justificativa:** a métrica principal escolhida precisa estar justificada na documentação, isso é cobrado no barema

A métrica principal é escolhida antes dos experimentos. Definida depois de ver os resultados, ela vira justificativa retroativa.

Estratégias para o desbalanceamento

- **Pesos de classe na função de perda:** primeira opção, porque não altera os dados e é simples de justificar
- **Ajuste de limiar:** escolhido na curva precisão-revocação da validação, e não no teste
- **Reamostragem:** subamostragem da majoritária, sobreamostragem ou SMOTE, aplicadas apenas na partição de treino
- **Agregação temporal:** mudar a unidade de análise, de hora para dia ou de dia para semana, reduz o desbalanceamento e aproxima o modelo da decisão real

Validação e teste permanecem com a distribuição original. Reamostrar o teste produz uma métrica que não existe na operação.

Artefatos da Sprint 3

Modelo com RNN e API de interface, e análise financeira do projeto.

Artefato 1: implementação de modelo com RNN

Objetivo: aprimorar os modelos apresentados até aqui. As comparações quanto à evolução do modelo devem ser apresentadas.

Modelo: implementado com uma rede neural recorrente, treinado com os dados fornecidos pelo parceiro e avaliado com as métricas definidas na documentação do modelo.

Documentação: atualizada com a descrição do problema, a descrição dos dados, a descrição do modelo e a descrição dos resultados.

O modelo anterior não deve ser retirado. A RNN é mais um modelo adicionado ao conjunto, e a comparação entre eles faz parte da entrega.

Artefato 1: API de interface

- Implementar uma API que integre o modelo de predição, utilizando um framework como o FastAPI
- A API recebe uma requisição com os dados necessários para a predição e retorna a predição
- A documentação da API deve ser entregue junto com a documentação do modelo

Pontos de atenção

- O contrato de entrada precisa ser compatível com a janela de observação usada no treino
- O mesmo pré-processamento do treino precisa ser aplicado na inferência
- Retornar a probabilidade e a decisão obtida com o limiar adotado
- Versionar o modelo servido e registrar qual versão respondeu cada requisição

Artefato 1: barema de correção

Modelo com RNN, justificativa das escolhas, métricas de avaliação e API implementada.

Faixa	Critério
0,0 a 1,0	Não iniciou. Os estudantes não iniciaram o desenvolvimento.
1,1 a 5,0	Informações incompletas. Iniciou a construção do modelo, mas não justificou nenhuma das escolhas e não apresentou nenhuma métrica de avaliação do modelo.
5,1 a 7,0	Entrega parcial. Iniciou a construção do modelo, mas não justificou as escolhas realizadas e não apresentou as métricas de avaliação. Ainda não tem API implementada.
7,1 a 9,5	Entrega completa. Construiu o modelo, justificou todas as escolhas e apresentou todas as métricas de avaliação. A API foi corretamente implementada.
9,6 a 10,0	Superou. Superou as expectativas com a entrega do artefato.

Artefato 2: análise financeira do projeto

- Projetar o custo de elaboração do protótipo, considerando a prova de conceito em 12 meses e o projeto implementado em um ciclo mínimo de 12 meses
- Apresentar as projeções de custos e de receitas que o parceiro pode ter relacionadas ao projeto no período de um ano
- Descrever os critérios utilizados na construção da análise, deixando as premissas explícitas
- A entrega acontece dentro da documentação do grupo

Categorias esperadas

Investimento inicial, custos fixos e variáveis, custos diretos e indiretos, custos operacionais (infraestrutura em nuvem, licenças e equipe), receitas recorrentes e ganhos obtidos pela redução de paradas.


Artefato 2: barema de correção

Projeções para os dois cenários, categorias discriminadas e critérios descritos.

Faixa	Critério
0,0 a 1,0	Não iniciou. Os estudantes não iniciaram o desenvolvimento.
1,1 a 5,0	Informações incompletas. Existem estimativas, mas incompletas ou apresentadas apenas para um dos cenários. Não há detalhamento de critérios, ou eles são superficiais e sem justificativa, e falta base lógica para os valores.
5,1 a 7,0	Entrega parcial. As projeções contemplam os dois cenários em 12 meses, mas de forma genérica. Custos e receitas aparecem com pouca fundamentação e sem detalhar categorias. Os critérios são mencionados de forma resumida.
7,1 a 9,5	Entrega completa. Projeções claras para os dois cenários, com valores discriminados por categoria, período de 12 meses, premissas explícitas e critérios bem descritos, coerentes com o escopo do projeto.
9,6 a 10,0	Superou. Superou as expectativas com a entrega do artefato.

Fechamento: o que precisa estar pronto ao final da sprint

- Definição do rótulo registrada, com janela de observação, horizonte de predição e critério de associação entre alarmes e chamados
- Tabela única de comparação entre os modelos, com o modelo anterior preservado
- Proporção de positivos reportada e estratégia de desbalanceamento justificada
- Métrica principal escolhida e justificada, com o limiar de decisão definido
- API em execução e documentada, com exemplo de requisição e de resposta
- Análise financeira nos dois cenários, com os critérios descritos
- Backlog da sprint no Kanban, com o WIP respeitado e os cards puxados pela equipe



Murilo Zanini de Carvalho

murilo.zanini@prof.inteli.edu.br

